CitizenTech: Queimadas no Brasil (2024-2025)

Aluno: Luiz Brito · **Data:** 08/11/2026 · **Disciplina:** Big Data & Analytics (Global Solution)

Pipeline de Big Data & Analytics para entender onde, quando e em que condições ocorrem os focos de queimada no Brasil, e apoiar a priorização de ações de prevenção e fiscalização.

1. Investigação do problema

Problema: focos de queimada são uma emergência climática recorrente, com impacto em saúde respiratória, biodiversidade, emissões de carbono e economia local.

Quem é afetado: populações de municípios com alta incidência de fogo (principalmente Amazônia e Cerrado), órgãos ambientais (IBAMA, ICMBio, secretarias estaduais), Defesa Civil e brigadas de incêndio.

Dimensão analisada: distribuição geográfica (município e bioma), evolução mensal, condições climáticas associadas (dias sem chuva, precipitação, risco de fogo) e intensidade do fogo (FRP).

Decisões que os dados apoiam:

- Onde posicionar brigadas e recursos de combate antes do período crítico.
- Quais municípios precisam de fiscalização (fogo fora de condição climática de risco).
- Quando antecipar campanhas de prevenção.

Viabilidade: o INPE publica os focos com dados abertos, granularidade por foco e código IBGE do município, o que permite cruzar com dados demográficos oficiais.

2. Catálogo de dados

Fonte	Origem	Volume	Atributos usados
Focos de queimada (mensal, Brasil)	INPE BDQueimadas	24 arquivos, 11.608.772 focos (todos os satélites)	`id`, `lat`, `lon`, `data_hora_gmt`, `satelite`, `municipio_id`, `estado`, `bioma`, `numero_dias_sem_chuva`, `precipitacao`, `risco_fogo`, `frp`
Censo 2022: população, área e densidade	IBGE SIDRA, tabela 4714	5.570 municípios	código do município, população, área (km²), densidade

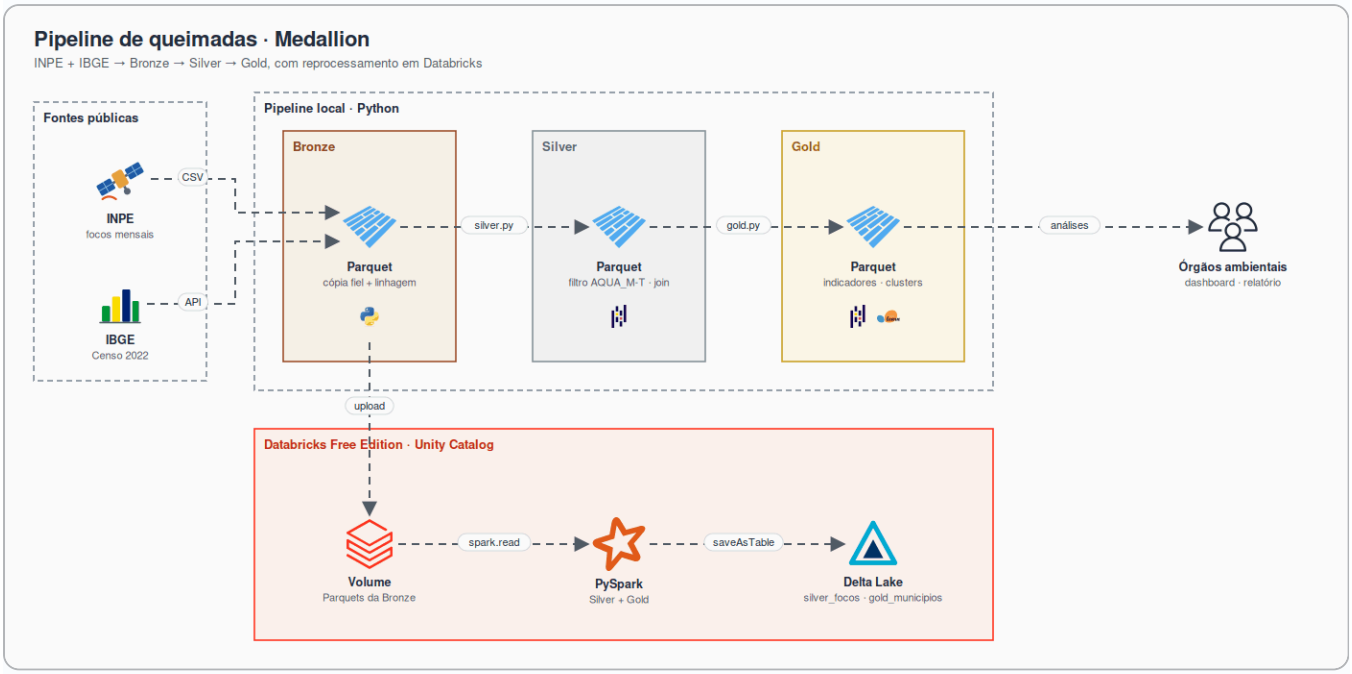
Por que essas fontes:

- O INPE é a referência oficial de monitoramento de fogo no Brasil. O arquivo mensal traz variáveis climáticas por foco, que o arquivo anual não tem.
- O IBGE permite normalizar os focos por área e população, evitando que municípios grandes dominem os rankings só pelo tamanho.
- A chave de integração é o código IBGE do município (`municipio_id`), presente nas duas fontes.

Confiabilidade:

- Foi usado apenas o **satélite de referência (AQUA_M-T)**, que forma a série histórica oficial do INPE. Validação: setembro/2024 tem 83.154 focos tanto no arquivo mensal filtrado quanto no arquivo anual oficial de referência, e o total de 2024 (278.299) também bate.
- O valor `-999` é usado pelo INPE para "sem dado" e foi convertido em nulo (menos de 2% dos registros).
- Classes de risco seguem o método oficial do INPE (RiscoFogo_Sucinto.pdf).

3. Arquitetura (Medallion)



Camada	Conteúdo	Decisões
Bronze	Dados originais de todos os satélites, colunas como texto	Parquet em vez de CSV (408 MB de CSV viram ~50 MB). Colunas `_fonte` e `_ingerido_em` para rastreabilidade. Ingestão idempotente (pula meses já baixados).
Silver	414.692 focos do satélite de referência, tipados e integrados ao IBGE	Filtro aplicado na leitura do Parquet. `-999` vira nulo. Deduplicação por `id`. Join pelo código IBGE: 0 focos sem correspondência.
Gold	`municipios` (5.570 linhas), `bioma_mes` (144 linhas), `correlacao_clima`, `clusters`	Inclui municípios com zero focos, necessário para taxas e comparações justas.

Tecnologias: Python, pandas, PyArrow (Parquet), scikit-learn, SciPy. Databricks Free Edition com PySpark e Delta Lake na parte de processamento distribuído.

4. Como executar

```
uv sync
uv run python bronze.py    # baixa INPE + IBGE (alguns minutos, ~615 MB)
uv run python silver.py
uv run python gold.py
uv run python analise.py
```

Databricks: importar `databricks/queimadas_spark.py`, enviar os Parquets da Bronze para o volume `workspace.default.queimadas` e executar.

---

5. Feature Engineering

Feature	Construção	Por que importa
`classe_risco`	`risco_fogo` em 5 faixas oficiais do INPE (mínimo a crítico)	Traduz um índice contínuo em categorias usadas pelos órgãos de resposta
`pct_risco_critico`	% de focos do município com risco > 0,95	Separa fogo em condição climática extrema de fogo "fora de época"
`focos_por_1000km2`	focos / área × 1000	Normaliza pelo tamanho do município
`focos_por_100mil_hab`	focos / população × 100.000	Mede exposição da população
`var_anual_pct`	(focos 2025 - focos 2024) / focos 2024	Mostra tendência por município
`frp_medio`	média do Fire Radiative Power	Intensidade do fogo, proxy de severidade
`bioma_predominante`	bioma mais frequente nos focos do município	Contexto ecológico para a recomendação
`ano`, `ano_mes`	extraídos de `data_hora_gmt`	Base para sazonalidade e evolução

6. Indicadores

Indicador	Definição	Dados	Interpretação
Total de focos	contagem de focos do satélite de referência	INPE	Dimensão do problema. 2024: 278.299; 2025: 136.393 (queda de 51%)
Densidade de focos	focos por 1.000 km²	INPE + IBGE	Prioriza onde o fogo é concentrado, não só onde o território é grande. Usar com volume mínimo (municípios pequenos distorcem)
Focos por 100 mil hab.	focos / população	INPE + IBGE	Exposição humana
% em risco crítico	focos com risco de fogo > 0,95	INPE	Alto: fogo ligado à seca. Baixo: indício de queima por manejo ou ação humana
FRP médio	intensidade média	INPE	Severidade, ajuda a dimensionar o tipo de combate
Focos por bioma e mês	contagem mensal por bioma	INPE	Sazonalidade: pico de agosto a outubro

7. Análises avançadas

Correlação clima × focos (Spearman, por bioma, 24 meses):

Bioma	Dias sem chuva	Precipitação
Cerrado	0,88	-0,78
Mata Atlântica	0,82	-0,51
Caatinga	0,74	-0,42
Pantanal	0,63	-0,28 (não sig.)
Amazônia	0,52	-0,49
Pampa	0,24 (não sig.)	-0,14 (não sig.)

Spearman foi escolhido porque os focos têm distribuição muito assimétrica (de 30 mil a 800 mil por mês).

Clusterização de municípios (KMeans, k = 5 escolhido pela silhueta, municípios com 10 ou mais focos, features padronizadas):

Perfil	Municípios	Característica
Hotspots	683	70% de todos os focos
Seca prolongada	566	63 dias sem chuva, 86% em risco crítico
Fogo intenso	123	FRP cerca de 4× a média
Moderado	1.059	20 dias sem chuva, 75% em risco crítico
Baixo risco climático	532	só 11% em risco crítico: fogo fora da seca

Limitações: silhueta de 0,25 indica grupos com sobreposição, então os perfis servem para priorizar, não como categorias rígidas. Apenas dois anos de dados, e 2024 foi um ano de seca extrema, o que exagera a queda em 2025.

---

8. Dashboard

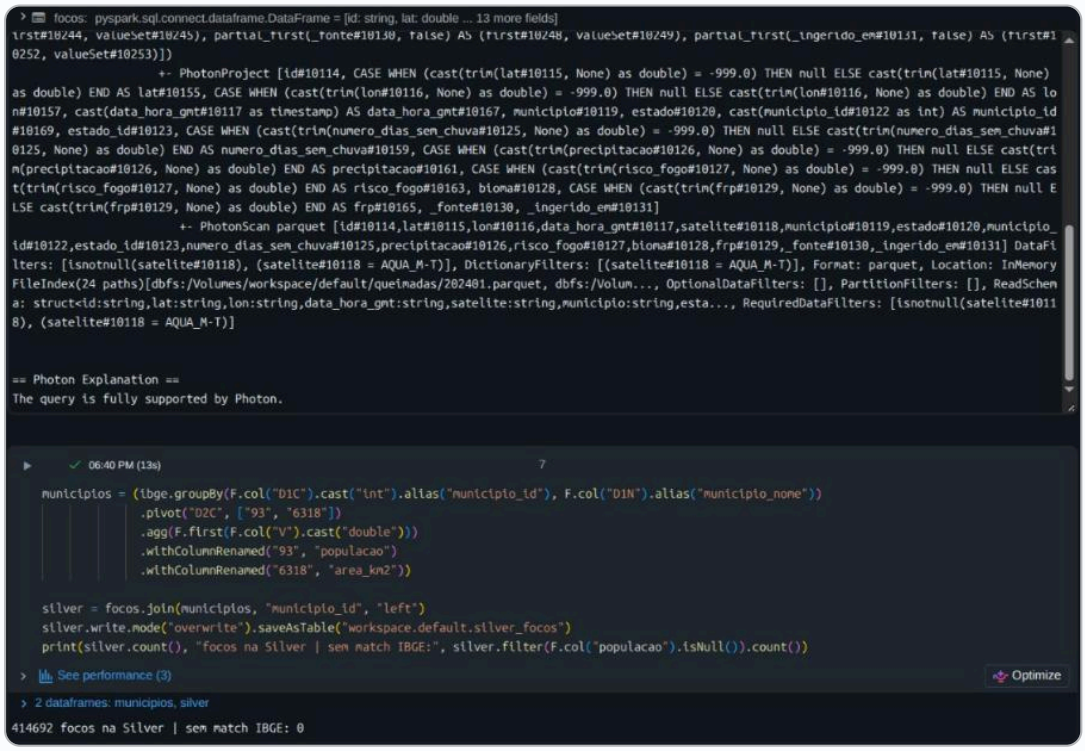
AI/BI Dashboard no Databricks, alimentado pelas tabelas Delta `silver_focos` e `gold_municipios` e pelos clusters. As consultas estão em `databricks/dashboard.sql`.



9. Experimentação com Databricks e Apache Spark

Notebook `databricks/queimadas_spark.py`, executado no Databricks Free Edition (compute serverless com Photon).

O que foi investigado	Como foi feito
Carregar datasets	`spark.read.parquet` sobre os 24 Parquets da Bronze num volume do Unity Catalog (11,6 milhões de linhas)
Transformações em DataFrames	filtro de satélite, `trim` + `cast`, `-999` para nulo, `to_timestamp`, `dropDuplicates`
Junção de fontes	pivot do IBGE (`groupBy().pivot()`) e `join` pelo código do município
Agregações e consultas	`groupBy().agg()` por município e consulta SQL (`%sql`) sobre a tabela Gold
Armazenar e consultar	`saveAsTable` em Delta Lake (`silver_focos`, `gold_municipios`), consumidas pelo dashboard
Processamento distribuído	leitura em paralelo dos 24 arquivos e plano físico analisado com `explain()`



O que o plano físico mostra:

- O filtro `satelite = AQUA_M-T` aparece dentro do `PhotonScan parquet` (`DataFilters` e `DictionaryFilters`). O Spark descarta as linhas dos outros satélites já na leitura, sem carregar os 11,6 milhões de registros para depois filtrar.
- As colunas `pais` e `pais_id`, removidas no código, nem são lidas do arquivo (*column pruning*).
- O resultado bate com o pipeline local: 414.692 focos na Silver, 0 sem correspondência no IBGE e o mesmo ranking de municípios na Gold.

Discussão:

- **Características:** a mesma lógica do pandas foi escrita de forma declarativa e o otimizador decidiu a ordem de execução. As tabelas Delta ficaram disponíveis direto para SQL e para o dashboard, sem exportar arquivos.
- **Possibilidades:** com o histórico completo do INPE (desde 2003, todos os satélites), o volume passa de centenas de milhões de linhas e não cabe na memória de uma máquina. Nesse cenário o Spark escala sem mudar o código.
- **Limitações:** com o volume atual (cerca de 415 mil focos filtrados), o pandas local foi mais simples e rápido de iterar. O serverless leva alguns segundos para iniciar. O modo ANSI do SQL dá erro em divisão por zero, o que exigiu `NULLIF`. Na Free Edition o dashboard não tem link público: só usuários cadastrados na conta conseguem abrir.

Relatório executivo: Queimadas no Brasil (2024-2025)

Para: órgãos ambientais e Defesa Civil (organização contratante) **Base:** 414.692 focos do satélite de referência do INPE, cruzados com o Censo 2022 do IBGE para os 5.570 municípios.

---

1. O que os dados revelam

- O fogo é **sazonal e concentrado**: 63% dos focos ocorrem entre agosto e outubro. O pior mês da série foi setembro/2024, com 83.154 focos.
- O fogo acompanha a **seca**: nos meses com mais dias sem chuva há mais focos em todos os biomas com volume relevante (Spearman de 0,52 na Amazônia a 0,88 no Cerrado).
- 60% dos focos ocorreram em condição de **risco de fogo crítico** (índice INPE acima de 0,95).
- Os focos caíram **51%** de 2024 (278.299) para 2025 (136.393). Mas 2024 foi um ano de seca extrema, então parte da queda é climática e não pode ser atribuída só a ações de combate.

---

2. Situações, regiões e grupos que merecem atenção

Prioridade	Onde	Evidência
Alta, tendência de alta	**Matopiba e Caatinga** (MA, BA, PI, TO)	Caatinga **+16%** em 2025. Maranhão virou o estado com mais focos (24.300). Bahia +32%. Barra (BA) passou de 207 para 701 focos.
Alta, volume	Arco do desmatamento (sul do PA, norte do MT, AM, RO)	São Félix do Xingu, Altamira, Novo Progresso e Apuí lideram a série. PA e MT somam 33% dos focos.
Média, recorrência	683 municípios do perfil **Hotspots**	Concentram 70% de todos os focos.
Fiscalização	532 municípios do perfil **Baixo risco climático**	Só 11% dos focos em risco crítico: fogo fora da condição de seca, indício de queima por manejo ou ação humana.

3. Padrões e tendências identificados

- **Deslocamento do fogo:** em 2025 a queda foi forte na Amazônia (-69%) e no Pantanal (-95%), mas o fogo cresceu na Caatinga (+16%) e no Pampa (+66%, ainda com volume baixo). **591 municípios** tiveram mais focos em 2025 do que em 2024.
- **Pico mais curto em 2025:** a concentração em agosto a outubro caiu de 66% para 55%, com focos mais espalhados ao longo do ano.
- **Perfis distintos:** a clusterização separou cinco perfis de município (Hotspots, Seca prolongada, Fogo intenso, Moderado e Baixo risco climático). Cada perfil pede uma resposta diferente.

4. Decisões que os dados permitem tomar

1. **Pré-posicionar brigadas em julho**, antes do pico, nos municípios Hotspots e Seca prolongada, priorizando pelo indicador de focos por 1.000 km² com volume mínimo de focos.
2. **Redirecionar parte dos recursos para o Matopiba e a Caatinga**, onde o fogo cresceu em 2025, em vez de repetir a distribuição de 2024, centrada na Amazônia.
3. **Fiscalização e educação ambiental** nos municípios de Baixo risco climático, onde o fogo não se explica pelo clima.
4. **Equipamento de maior porte** nos 123 municípios de Fogo intenso (FRP cerca de 4× a média), onde o fogo é mais severo.
5. **Alerta antecipado** quando os dias sem chuva subirem num bioma, dada a correlação forte, especialmente no Cerrado.

5. Resultados a acompanhar

Indicador	Meta de acompanhamento	Fonte
Focos em agosto a outubro por bioma	Queda ano a ano, comparada a anos de clima semelhante	`focos_bioma_mes`
Focos nos municípios priorizados	Queda maior que a média nacional	`gold_municipios`
% de focos em risco crítico	Estável. Se cair com focos estáveis, o fogo está migrando para fora da seca	`silver_focos`
Municípios que mudam de perfil	Saída do perfil Hotspots	`clusters`
Focos na Caatinga e no Matopiba	Reverter a alta de 2025	`focos_bioma_mes`

O pipeline é reprodutível: basta reingerir os meses novos do INPE (`bronze.py` é idempotente) e rodar Silver, Gold e análises para atualizar todos os indicadores.

Limitações

- Apenas dois anos de série. Para separar efeito do clima de efeito de política pública, é preciso estender o histórico (o INPE disponibiliza desde 2003).
- Focos de calor não equivalem a área queimada: um incêndio grande pode gerar vários focos.
- Os perfis de clusterização têm sobreposição (silhueta 0,25) e servem para priorizar, não para classificar de forma rígida.